BENCHMARK DESIGN · v0.3

VideoAgentBench 50-Task Suite

开放式视频创作 Agent 综合评测基准

从普通用户的模糊需求到完整视频交付

五大场景 · 五十项综合任务 · 每题双轮创作

包含自然提示词、隐藏评测点、素材规格与修改反馈

Research Design / Pilot Specification

2026.11.01

RESEARCH PROPOSAL

设计摘要

视频制作不仅是“生成漂亮画面”，还包括研究、判断、导演、剪辑、沟通和返工。本设计将所有任务输入写成普通人的自然语言，并把严格要求放入评测端，尽可能避免 Agent 仅靠执行详细清单得分。

1. 核心定义

VideoAgentBench 评测的是完整视频制作 Agent，而非单纯 Text-to-Video 模型。任务输入模拟普通用户：短、模糊、主观，有时带着未经验证的认知；用户不会提供详细拍摄脚本、字幕标准、镜头数量或工具链。

> **研究问题：** Agent 能否推导隐含需求，自主搜集资料与素材、组织叙事、制作视觉与声音、交付可播放视频，并在收到自然语言反馈后做必要且精准的修改？

50	5 × 10	2	100
任务定义	场景类别	轮次 / 每题	首轮评分满分

自然语言需求 用户侧可见 → **自主研究与制作** Agent + tools → **成片 v1 / v2** 真实可播放 → **分层评分** 自动 + 盲评

2. 任务构成与覆盖

五大类别各 10 道，包含此前讨论的 DART（A01）、咖啡店（B11）、时间异常短片（C21）。下方每题均提供：用户原始提示词、素材包建设规格、隐藏评测点和第二轮用户反馈。**隐藏评测点只给评测者，不发送给参测 Agent。**

组别	场景	主要测量的能力	题数
A	信息检索与科学解释	Research-to-Video	10
B	商业宣传与品牌传播	Brief-to-Commercial	10
C	创意叙事与视觉特效	Story-to-Film	10
D	个人影像与纪录剪辑	Footage-to-Documentary	10
E	复杂约束与跨模态制作	Mixed-Constraint Production	10

3. 单题的执行协议

Stage A / 初版制作。 开放该题的用户提示词和允许使用的素材。Agent 可检索网络、使用生成模型和剪辑工具；最终必须提交可播放的成片 v1。允许最多 2 次澄清提问，但只在确有关键歧义时计为合理；答复由预设用户模拟器提供，不能临时人工帮助。

Stage B / 修改反馈。 第一版完成后，才发送该题“二轮反馈”，要求在 v1 基础上修改并交付 v2。Agent 可修改脚本、局部素材、特效、字幕和音频，不要求必须保留完全相同的工程结构，但会惩罚无关的大范围改动。

完成定义。 至少提交 final_v1.mp4、final_v2.mp4、execution_log.jsonl、assets_manifest.json。无法播放或缺少视频的任务视为未完成。日志和来源清单是供评测使用的系统级交付，不由普通用户提示词显式要求。

4. 固定与开放的评测资源

开放网络类： 需要固定检索快照日期、地理适用范围和允许使用的来源清单。允许真正联网时，必须完整记录引用与检索时间，并与冻结环境的结果分开排名。

冻结素材包类： 需要未来正式制作、审查并授权原始片段（含时间码、镜头标签及 consent），建立素材哈希。任务里写出的“待制作素材”仅是采集规格，不代表本 PDF 已经附带视频素材。

混合类： 既要冻结原始素材，也要为允许的外部事实检索建立溯源规则。对虚构品牌和虚构商业信息，应由任务事实卡作为唯一权威来源。

TASK COLLECTION / A

信息检索与科学解释 · 10 题

10 道开放网络检索型任务。重点是事实核查、证据权衡和抽象概念可视化。

A01 DART：小行星轨道真的被撞歪了吗？

60–100秒 · 高

发给 Agent 的用户原话

> 最近刷到 NASA 拿飞船撞小行星那个事，听说真的把轨道撞歪了？我想做个一分钟多点的视频发 B 站，最好有点电影感，但别搞成世界末日，也别像上课一样无聊。资料素材你自己找，直接做成视频。

输入资源建设规格：无需预置实拍；允许检索官方公开影像与研究资料。

执行模式：开放网络　**主要能力：**R,P,V,I

评测者隐藏观察点

- 核实 DART 的真实目标与实验结果，区分“轨道周期变化”和“炸毁小行星”。
- 辨别双小行星绕转与整个系统绕太阳的轨道，不混淆数值。
- 以可读动画解释动量传递；标识真实影像、模拟示意和艺术表达。

第二轮用户反馈： “开头有点像营销号，而且那个轨道变化我还是没看懂。别的地方还不错，主要改这两处。”

A02 第一张黑洞照片为什么糊？

60–90秒 · 中

发给 Agent 的用户原话

> 我看到那张很有名的黑洞照片，感觉就是个橘色甜甜圈。帮我做条视频解释一下它到底拍到了什么，别讲太多公式，但希望看完觉得挺神奇。

输入资源建设规格：允许检索 EHT 官方图像、望远镜示意和授权天文素材。

执行模式：开放网络　**主要能力：**R,P,V

评测者隐藏观察点

- 讲清事件视界望远镜的基本原理、成像方法及图像局限。
- 不将黑洞阴影或周围辐射错误解释为“拍到黑洞表面”。
- 用影像尺度、望远镜阵列等图解帮助理解。

第二轮用户反馈： “原理部分还是有点像讲课，能不能更直观一点？那张经典照片别删。”

A03 深海黑烟囱里为什么有生命？

60–100秒 · 中

发给 Agent 的用户原话

> 深海不是又黑又冷吗，为什么海底冒热水的地方还有一堆生物？想做个有探索感的短视频，最好能让人有种慢慢潜到海底的感觉。

输入资源建设规格：公开科研机构海底影像与生物资料，许可清单待建设。

执行模式：开放网络　**主要能力：**R,P,V,E

评测者隐藏观察点

- 正确区分热液喷口、生物共生与化能合成。
- 不把不同海域、不同物种镜头误标为同一实地拍摄。
- 构建由海面到海底的空间和知识递进。

第二轮用户反馈：“生物挺漂亮的，但我没明白它们到底靠什么活。能把这个讲清楚些吗？”

A04 城市里为什么晚上还这么热？

45–75秒 · 中

发给 Agent 的用户原话

> 夏天总觉得城区晚上比郊外热得多，想做个视频聊聊这个现象。希望看着像城市观察纪录片，不要一上来就是一堆数据图。

输入资源建设规格：公开气象/城市研究资料；可使用许可明确的城市素材。

执行模式：开放网络　**主要能力：**R,P,I

评测者隐藏观察点

- 说明热岛成因与适用范围，避免把天气差异一概归因。
- 城市实拍与温度叠层需避免伪装成实测热成像。
- 用建筑、地表、植被与夜间散热组织画面。

第二轮用户反馈：“后面建议有点空泛。我更想知道为什么到了晚上热还散不掉。”

A05 日食和月食到底差在哪？

50–80秒 · 低

发给 Agent 的用户原话

> 下次再有人问我日食月食差别，我想能直接发条视频给他。别做成课件，可以用很漂亮的太空视角讲清楚。

输入资源建设规格：公开天文机构说明与适用素材；模拟图需自制或注明。

执行模式：开放网络　**主要能力：**R,V,I

评测者隐藏观察点

- 太阳、地球、月球的位置和遮挡关系准确。
- 动画的观察视角与真实观测效果可区分。
- 篇幅短而完整，避免不必要的宇宙奇观镜头。

第二轮用户反馈：“你那个镜头绕来绕去，我反而看糊涂了。换种更简单的表现吧。”

A06 旧电池最后去哪了？

60–100秒 · 高

发给 Agent 的用户原话

> 家里攒了一盒废电池，突然想知道它们最后怎么处理。帮我做个短视频，像是在跟着一颗电池旅行，能查到的资料你自己查。

输入资源建设规格：需固定一个适用地区和电池类型；可使用流程示意和许可素材。

执行模式：开放网络　**主要能力：**R,P,I

评测者隐藏观察点

- 区分一次电池、锂离子电池与当地回收政策；先限定叙述范围。
- 回收链条不臆造，明确流程地区差异与不确定性。
- 叙事具“旅程”感，但不以动画取代事实。

第二轮用户反馈：“看起来好像所有电池最后都走同一套流程？这个我有点怀疑，帮我改准确。”

A07 火星上真的有水吗？

60–90秒 · 中

发给 Agent 的用户原话

> 网上老说火星发现水，隔两年就上一次热搜。到底是有湖、冰还是只有一点痕迹？帮我做个能把这事讲明白的视频。

输入资源建设规格： NASA/ESA 官方影像、测量结果及科学解释。

执行模式： 开放网络　**主要能力：** R,P,V

评测者隐藏观察点

- 区分现存水冰、历史液态水证据和未证实的当前液态水。
- 解释不同报道指向不同类型证据，而非“发现又被推翻”。
- 将卫星影像与概念模拟分开呈现。

第二轮用户反馈： “能不能不要一上来就下结论？我想先跟着几个发现慢慢理解。”

A08 3D 打印房子真能一天建完？

60–90秒 · 高

发给 Agent 的用户原话

> 刷到那种机器挤混凝土造房子的视频，看着太酷了。帮我做一期，顺便搞清楚“几小时盖一栋房”到底算不算真的。

输入资源建设规格： 公开施工案例；需保留“打印结构”和“完整交付”的区分证据。

执行模式： 开放网络　**主要能力：** R,P,I

评测者隐藏观察点

- 区分打印墙体时间、整体施工工期与其他工序。
- 商业宣传数据交叉核实并标明适用条件。
- 时间线可视化不把快放错当实时施工。

第二轮用户反馈： “我朋友说还得装屋顶和水电，你的视频好像没提这部分。补进去但别太长。”

A09 极光到底怎么来的？

50–90秒 · 中

发给 Agent 的用户原话

> 看到朋友去北边拍的极光太漂亮了。能帮我做一个既有氛围又能解释原理的短视频吗？想知道那些光为什么会动。

输入资源建设规格：空间天气机构、极光公开素材；来源可追踪。

执行模式：开放网络　**主要能力：**R,V,E

评测者隐藏观察点

- 太阳风、磁层与高层大气发光的关系不失真。
- 时间流逝镜头、模拟磁力线与实拍区分。
- 画面展示的颜色与机制不被过度简单化。

第二轮用户反馈：“画面很好看，但是为什么主要出现在高纬度我还是不知道。加进去，别变成 PPT。”

A10 古罗马混凝土真的会自愈？

60–100秒 · 高

发给 Agent 的用户原话

> 听说古罗马的混凝土比现代的还牛，裂了还能自己长好。这是真的吗？想做条古建筑相关的科普，气质沉稳点，别上来就吹古人吊打现代。

输入资源建设规格：学术研究、遗址影像及授权建筑素材；避免把推测当定论。

执行模式：开放网络　**主要能力：**R,P,I

评测者隐藏观察点

- 区分研究提出的机制、实验结果和夸张媒体标题。
- 不做跨时代材料性能的绝对化比较。
- 历史建筑、显微结构与修复动画表达关系清楚。

第二轮用户反馈：“你说现代混凝土不行那句有点武断，调整一下，保留前面的古建筑氛围。”

TASK COLLECTION / B

商业宣传与品牌传播 · 10 题

10 道素材+品牌事实卡任务。重点是用户审美理解、卖点选择与商业信息真实性。

B11 街角咖啡店开业

30–60秒 · 中

发给 Agent 的用户原话

> 我们咖啡店快开业了，拍了一堆素材，你帮我做个发抖音的宣传视频吧。想要有质感、看着舒服，别太像硬广，最好让人看了想过来坐坐。视频你自己安排。

输入资源建设规格：待制作：店内/咖啡制作/客人授权镜头 15–20 条、Logo、店铺事实卡。

执行模式：冻结素材包　**主要能力：**P,E,I

评测者隐藏观察点

- 从低质量/重复素材中筛选有效镜头，形成连贯宣传叙事。
- 色彩和节奏体现“小店有人情味”，不虚构优惠/营业信息。
- 文字、Logo 与真实品牌资料一致，顾客肖像有授权。

第二轮用户反馈：“有点太像大品牌广告了，能不能更有人情味？咖啡制作那段挺好，尽量保留。”

B12 一家旧书店的小视频

30–60秒 · 中

发给 Agent 的用户原话

> 我朋友开的二手书店不太会宣传，我拍了点书架、店猫和门口的视频。想剪个让人愿意逛一逛的短片，不要那种一直喊“快来买”的。

输入资源建设规格：待制作：书店室内/书本/店猫 12–18 段；营业时间、地址仅放在事实卡。

执行模式：冻结素材包　**主要能力：**P,E,I

评测者隐藏观察点

- 用空间探索和细节建立书店氛围而非重复堆特写。
- 不误用书籍文字与真实书名，不编造活动。
- 素材有猫、有人、无人的段落衔接自然。

第二轮用户反馈：“现在太文艺了，像个安静的艺术电影。能让人知道这其实是一家能逛的店吗？”

B13 陶艺工作室体验课

30–60秒 · 中

发给 Agent 的用户原话

> 我们做了一个陶艺体验课，手机拍了一些拉坯、上釉和成品。能不能剪一条让没玩过的人也想来试试的？感觉轻松一点，别太高端。

输入资源建设规格：待制作：体验课原始素材、合法使用的成品照片、课程事实卡。

执行模式：冻结素材包　**主要能力：**P,V,I

评测者隐藏观察点

- 分清制作步骤和时间跨度，不用虚假“一次成型”镜头。
- 新手友好与真实体验一致，不许诺虚构优惠/成果。
- 手部动作与声音节奏匹配，局部转场自然。

第二轮用户反馈： “看完像是师傅在做陶瓷，跟普通人没关系。加一点学员体验的感觉。”

B14 独立跑鞋品牌首发

30–50秒 · 高

发给 Agent 的用户原话

> 新跑鞋准备上线了，我有产品图和几段试跑视频。帮我做个有运动感的发布短片，别学大牌那些特别燃但听不懂的广告。

输入资源建设规格：待制作：无标识虚构品牌跑鞋产品素材、试跑镜头、真实规格卡。

执行模式：冻结素材包　**主要能力：**P,V,E

评测者隐藏观察点

- 运动镜头与产品细节有叙事关系，避免纯炫技。
- 缓震、重量等产品卖点只使用事实卡可验证信息。
- 动作、运动方向、镜头速度连续。

第二轮用户反馈： “运动感够了，但鞋子长什么样反而没看清。再调整一下。”

B15 一款小 App 的 40 秒介绍

30–60秒 · 高

发给 Agent 的用户原话

> 我做了个提醒自己专注的小 App，已经录了屏。帮我剪个能发到社交平台的视频，让人一眼看懂它能干什么，别像软件说明书。

输入资源建设规格：待制作：真实演示录屏 6–10 段、UI 截图、功能清单和产品图标。

执行模式：冻结素材包　**主要能力：**P,V,I

评测者隐藏观察点

- 从真实录屏提炼核心使用情境，不制造不存在的功能。
- UI 放大、遮罩、动效帮助辨认操作，不更改关键内容。
- 手机画面可读且不泄漏测试账号信息。

第二轮用户反馈： “你把动画做得挺酷，但好像没讲清为什么我要用它。把场景带出来。”

B16 小博物馆的新展览

30–60秒 · 高

发给 Agent 的用户原话

> 我们有个小型摄影展快开了，手里是布展过程和几张参展作品。想发条预告，既有点艺术感又别故弄玄虚，让人知道来看什么。

输入资源建设规格：待制作：获授权展览作品、布展素材、展期地点与版权说明。

执行模式：冻结素材包　**主要能力：**R,E,I

评测者隐藏观察点

- 尊重摄影作品版权与展示条件，不随意修改作品内容。
- 清楚传达展览主题及已提供的时间地点。
- 作品呈现与布展花絮衔接自然，文字不遮挡关键画面。

第二轮用户反馈： “大家看了不知道展览主题是什么。能让主题明确一点，但别加一大串字。”

B17 手工面包店早晨开炉

30–60秒 · 低

发给 Agent 的用户原话

> 我们每天早上做面包，拍了揉面、出炉这些画面。想做条看了就有食欲的小视频，有一点生活气息，不用一直介绍品种。

输入资源建设规格：待制作：15–20 段厨房/面包/门店镜头，真实产品清单。

执行模式：冻结素材包　**主要能力：**E,I

评测者隐藏观察点

- 流程时间关系基本成立，不把原料和成品错误配对。
- 声音、蒸汽、质感镜头有效营造氛围。
- 配乐与细节共同服务“温暖日常”而不是强促销。

第二轮用户反馈： “太多慢镜头了，看得有点困。想保留舒服的感觉，但节奏可以再有趣些。”

B18 露营装备租赁服务

40–70秒 · 中

发给 Agent 的用户原话

> 我们想做个露营装备租赁的小宣传片，拍了搭帐篷和收纳过程。核心是让新手觉得方便，不是卖很贵的装备，帮忙做得清楚一点。

输入资源建设规格：待制作：搭建/收纳/使用镜头、租赁服务条款摘要和真实价格卡。

执行模式：冻结素材包　**主要能力：**P,V,I

评测者隐藏观察点

- 强调真实租赁流程和费用边界，不承诺不存在的服务。
- 可视化展示帐篷搭建及收纳关键动作。
- 户外环境、产品状态和动作连续。

第二轮用户反馈： “现在像帐篷开箱广告，没体现“租”到底省了什么麻烦。调整一下。”

B19 旧衣改造工作室宣传

30–60秒 · 中

发给 Agent 的用户原话

> 我们做旧衣服改造，有几组改造前后的照片，还有缝纫过程。想剪一条有惊喜感的视频，但别太夸张，毕竟都是普通人穿的衣服。

输入资源建设规格：待制作：对应配对的改造前后图、缝纫镜头、店铺介绍。

执行模式：冻结素材包　**主要能力：**V,E,I

评测者隐藏观察点

- 严格配对前后对比，不能借换衣物制造不真实效果。
- 转场与节奏突出“变化”，保持材质与色彩准确。
- 不编造环保量化数字或收益。

第二轮用户反馈：“前后对比有点快，根本看不清改了什么。稍微放慢关键两组就好。”

B20 独立乐队的小型演出预告

20–50秒 · 高

发给 Agent 的用户原话

> 我们周末有个小演出，自己拍的彩排挺乱的。想做个有现场感的预告，不用很商业，最好让人想来听现场。

输入资源建设规格：待制作：获得表演者与录音授权的彩排片段、演出海报及准确票务信息。

执行模式：冻结素材包　**主要能力：**E,I

评测者隐藏观察点

- 以授权音轨为节奏核心，音画同步且不使用未经授权商业音乐。
- 地点/时间/票务信息可读，素材未伪装为真实演出现场。
- 保留现场质感，合理处理多机位与噪声。

第二轮用户反馈：“气氛很好，但演出时间和地点一闪而过，朋友说没看清。”

TASK COLLECTION / C

创意叙事与视觉特效 · 10 题

10 道剧情和 VFX 任务。重点是从有限素材进行故事规划、镜头一致性和特效叙事价值。

C21 时间突然出错了

45–90秒 · 高

发给 Agent 的用户原话

> 我拍了几段日常生活的视频，想剪个科幻小短片。大概是一个人发现时间不太对劲，身边的东西开始变得异常。要神秘一点，有几个不错的特效，但不要廉价 AI 感。故事你设计。

输入资源建设规格： 待制作：同演员同场景镜头 8–15 段、干净空镜、环境声。

执行模式： 冻结素材包　**主要能力：** P,V,E,I

评测者隐藏观察点

- 根据现有镜头设计成立的时间异常规则和完整短故事。
- 特效与演员动作、空间、光线一致且为叙事服务。
- 人物与道具状态稳定，结尾产生有效回响。

第二轮用户反馈： “效果挺酷，但怎么有点像恐怖片？我想更神秘、更孤独，结尾也再有意思点。”

C22 镜子里的自己慢半拍

45–75秒 · 高

发给 Agent 的用户原话

> 我在卫生间拍了几段对着镜子刷牙、洗脸的素材。能不能剪成一个人发现镜子里的自己反应慢半拍的小故事？不要靠突然吓人。

输入资源建设规格： 待制作：镜前表演、无人物镜面空镜、静态机位及光线参考。

执行模式： 冻结素材包　**主要能力：** P,V,E

评测者隐藏观察点

- 镜中错位从轻微到明显有递进；人物/镜像关系精确。
- 镜面区域遮罩、反射、照明和遮挡可信。
- 不用恐怖音效替代情节结构。

第二轮用户反馈： “前面太快就暴露了。能让观众先感觉不对劲，过一会才看出镜子有问题吗？”

C23 电梯多出不存在的一层

45–90秒 · 高

发给 Agent 的用户原话

> 朋友拍了电梯门、楼道和一个人等电梯的视频。想剪成个特别短的科幻悬疑片：电梯好像停在了不应该有的楼层。你来想怎么讲。

输入资源建设规格：待制作：电梯内外、楼道、按键与演员反应；虚构楼层标识模板。

执行模式：冻结素材包　**主要能力：**P,V,E

评测者隐藏观察点

- 空间切换与楼层逻辑自洽，不用随机惊吓支撑故事。
- 数字屏与开关门特效位置稳定且无明显穿帮。
- 悬念节奏建立后再揭示异常。

第二轮用户反馈：“感觉电梯一开门就很恐怖。我更想看那种合理但奇怪的设定，能改吗？”

C24 纸飞机带回一封回信

45–80秒 · 中

发给 Agent 的用户原话

> 我拍了小孩折纸飞机、从窗边放出去的几段素材。能不能做成一个温柔点的小故事，纸飞机飞走又带回来一句让人意外的话？

输入资源建设规格：待制作：纸飞机多个角度、开窗/桌面、空背景及手部镜头。

执行模式：冻结素材包　**主要能力：**P,V,I

评测者隐藏观察点

- 视觉连续性保证同一纸飞机的外观和飞行方向。
- 用合理运动路径与合成完成“回来”的关键镜头。
- 情感表达克制，结尾不依赖冗长字幕解释。

第二轮用户反馈：“有点太煽情了，想更轻一点。最后那句文字也能再含蓄一点吗？”

C25 雨滴停在半空

35–70秒 · 高

发给 Agent 的用户原话

> 雨天拍了一个人在路边撑伞的素材。能不能做成他走着走着发现雨突然不落了？想很有电影感，但保持真实。

输入资源建设规格：待制作：雨天街道镜头、空镜、雨声与合成遮罩参考。

执行模式：冻结素材包　**主要能力：**V,E,I

评测者隐藏观察点

- 雨的运动停止与人物继续运动区分清楚。
- 遮挡、景深、粒子位置与镜头运动一致。
- 转变瞬间有铺垫和听觉反馈，不只是定格画面。

第二轮用户反馈： “雨滴很好看，但感觉像整个画面暂停了。能突出只有雨停了、人还在动吗？”

C26 桌面植物倒着长

35–70秒 · 中

发给 Agent 的用户原话

> 我家有盆小植物，拍了浇水、放窗边的几段。想做个带点魔幻现实主义的小短片，植物好像在慢慢倒着生长。

输入资源建设规格：待制作：植物不同阶段授权镜头、固定机位、同一窗边场景。

执行模式：冻结素材包　**主要能力：**V,P

评测者隐藏观察点

- 逆向生长效果在叶片数量、阴影与时间变化上连贯。
- 故事含义从动作和环境中体现，而非生硬解释。
- 不使用明显跳切代替指定关键异象。

第二轮用户反馈： “效果好像普通延时倒放，看不出特殊感。能让人物也发现这个变化吗？”

C27 电脑屏幕提前显示明天

45–90秒 · 高

发给 Agent 的用户原话

> 我有一些人在电脑前加班、看手机、接电话的素材。能不能做个短片，电脑上突然出现了明天才会发生的事？不要写太多台词。

输入资源建设规格： 待制作：桌面实拍、可替换屏幕画面、后续事件镜头与键盘声。

执行模式： 冻结素材包　**主要能力：** P,V,E

评测者隐藏观察点

- 屏幕嵌入与透视、反射、光照一致。
- 因果线索前后对应，观众不靠字幕也能理解。
- 时间信息不能出现明显自相矛盾。

第二轮用户反馈： “后面那件事发生得太突然，我没理解它和电脑画面的联系。加强一下对应。”

C28 影子自己走开了

40–75秒 · 高

发给 Agent 的用户原话

> 有几段黄昏路灯下走路的视频。我想做个超现实短片，走着走着影子不跟着人了，感觉有点孤单，但别拍成鬼片。

输入资源建设规格： 待制作：静态/移动摄影下人物与影子素材、空地面素材。

执行模式： 冻结素材包　**主要能力：** V,E,I

评测者隐藏观察点

- 阴影方向、光源、接触关系保持物理一致性。
- 影子分离与人物反应形成叙事进展。
- 情绪偏孤独奇异而非恐吓。

第二轮用户反馈： “音效让我有点害怕了。画面别大改，主要重新处理声音和情绪。”

C29 房间里失去重力

45–80秒 · 高

发给 Agent 的用户原话

> 拍了房间里杯子、书、纸片和一个人发呆的镜头。想做一个很短的零重力场景，但别像大型特效大片，想要日常生活突然变奇怪的感觉。

输入资源建设规格：待制作：室内静态镜头、道具近景、干净背景与演员表演。

执行模式：冻结素材包　**主要能力：**V,P,E

评测者隐藏观察点

- 漂浮物体的路径、遮挡和接触关系一致。
- 特效风格克制并保留原场景生活质感。
- 镜头前后道具数量与位置可解释。

第二轮用户反馈：“东西都在飞，太热闹了。能只让一两个物体先浮起来，慢慢发现异常吗？”

C30 同一天出现两个版本

60–90秒 · 高

发给 Agent 的用户原话

> 我拍了一个人两次从家里出门的镜头，服装和动作有些不一样。能不能剪成两种人生在某个瞬间交错的短片？不用硬解释平行宇宙。

输入资源建设规格：待制作：两组相似但不同的人物动作、环境空镜、声音素材。

执行模式：冻结素材包　**主要能力：**P,E,I

评测者隐藏观察点

- 双时间线有可识别视觉标记而非混乱交叉。
- 同一人物的服装/动作差异被用于叙事。
- 镜头连接、声音先行和结尾让差异产生意义。

第二轮用户反馈：“我朋友说没看懂哪段是哪段。不要加旁白，能靠画面更清楚一点吗？”

TASK COLLECTION / D

个人影像与纪录剪辑 · 10 题

10 道实拍素材组织任务。重点是事件结构、镜头挑选、声音处理及叙事伦理。

D31 毕业季的两分钟

60–120秒 · 中

发给 Agent 的用户原话

> 毕业那几天我们拍了好多乱七八糟的视频，有操场、宿舍、合照和吃饭。能帮我剪个值得留着以后看的回忆视频吗？不要太煽情。

输入资源建设规格：待制作：跨三天多机位手机素材 25–40 段、授权合照、环境音。

执行模式：冻结素材包　**主要能力：**P,E,I

评测者隐藏观察点

- 从杂乱素材挑出可识别的人物与事件主线。
- 避免拿无关镜头充当重要时刻；时间顺序合理。
- 音乐情绪不过度操纵，保留真实环境声。

第二轮用户反馈：“中间有点像学校宣传片，我更想记住我们自己那些小事。”

D32 机器人比赛的真实一天

60–120秒 · 高

发给 Agent 的用户原话

> 我们比赛拍了好几个小时，从调车到上场都录了。想剪个一分钟多的纪录短片，给没看过比赛的人也能看懂，不用强行剪成逆袭爽片。

输入资源建设规格：待制作：准备/调试/比赛/采访镜头、可核实成绩记录和现场音。

执行模式：冻结素材包　**主要能力：**P,R,E

评测者隐藏观察点

- 赛事规则与结果依据事实卡，不能捏造胜利或故障。
- 通过赛前-现场-结果建立事件链，不只是音乐卡点。
- 利用多机位/计分牌/人物反应强化可理解性。

第二轮用户反馈：“热血是热血了，但好像不知道我们到底在比什么。前面加一点解释。”

D33 一家老修表店的采访

60–120秒 · 高

发给 Agent 的用户原话

> 我采访了一个修表的老师傅，也拍了一些他工作和店铺的细节。想剪成温柔的小人物纪录片，别搞那种“即将消失的手艺”煽情标题。

输入资源建设规格：待制作：两段访谈、工作现场 B-roll、采访授权及事实卡。

执行模式：冻结素材包　**主要能力：**R,P,E,I

评测者隐藏观察点

- 受访者观点必须来自真实语音，不拼接改变原意。
- B-roll 与叙述内容相符，字幕准确。
- 节奏和结构突出人物而非刻板怀旧叙事。

第二轮用户反馈： “感觉你替老师傅下结论了，他其实没说这个行业快没了。改得更尊重原话一点。”

D34 第一次徒步的真实记录

45–90秒 · 中

发给 Agent 的用户原话

> 周末第一次徒步，拍了出发、上山、迷路又找到路、到山顶这些片段。想剪个给朋友看的视频，有趣一点，但别假装是什么冒险大片。

输入资源建设规格：待制作：路径/天气/队友授权素材 20–30 段及简短日记。

执行模式：冻结素材包　**主要能力：**P,E,I

评测者隐藏观察点

- 尊重实际路线与事件顺序，不夸大危险。
- 山景镜头兼顾方向感和人物过程。
- 避免用不相干素材冒充路线中的景点。

第二轮用户反馈： “风景太多了，反而看不到我们怎么到山顶的。多加一点过程感。”

D35 一场生日惊喜的短片

45–90秒 · 中

发给 Agent 的用户原话

> 偷偷给朋友准备生日惊喜，大家分别拍了准备、躲起来和开门的过程。想做个热闹又自然的视频给他留纪念，别搞得像综艺节目。

输入资源建设规格：待制作：多手机拍摄、可用现场收音、拍摄者授权与时间点记录。

执行模式：冻结素材包　**主要能力：**E,P

评测者隐藏观察点

- 开门前的准备与揭晓节奏自然。
- 多视角对齐同一时刻，音频不突然跳变。
- 不暴露无关人物隐私和敏感个人信息。

第二轮用户反馈：“开门那下挺好，但之前铺垫太长了。让它更紧凑一点，别动惊喜现场。”

D36 从零做一个小装置

60–120秒 · 高

发给 Agent 的用户原话

> 我把做一个桌面小机器的过程都录了，螺丝、焊接、调试很多素材。想剪个两分钟以内的制作记录，让人知道我怎么从一堆零件做到能动起来。

输入资源建设规格：待制作：工序素材 30–50 段、过程照片、最终测试录像、正确操作说明。

执行模式：冻结素材包　**主要能力：**P,E,R

评测者隐藏观察点

- 保持关键制作因果链，不把失败试验当成功步骤。
- 技术文字与实际电路/机构对应；不编造测试性能。
- 通过工序压缩和特写体现学习过程。

第二轮用户反馈：“看着很顺利，但我当时卡在调试好久。想保留这个过程，不要全剪成成功集锦。”

D37 租来的房间改造前后

45–90秒 · 中

发给 Agent 的用户原话

> 租的房子收拾了一周，拍了改造前、收纳和最后布置好的样子。帮我剪条有成就感的视频，别剪得像买房装修公司广告。

输入资源建设规格：待制作：同机位前后镜头、过程记录、真实预算条目与注意事项。

执行模式：冻结素材包　**主要能力：**E,V,I

评测者隐藏观察点

- 严格匹配前后房间角度和同一处空间。
- 不将未提供的物件或费用虚构成改造结果。
- 剪辑突出真实过程与个人生活感。

第二轮用户反馈： “前后变化挺直观，但看不见中间怎么弄的，想多留一点过程。”

D38 夜市逛吃的一小时

45–75秒 · 中

发给 Agent 的用户原话

> 昨晚和朋友去夜市，拍了摊位、吃东西还有乱七八糟的聊天。想剪成一条有烟火气的短视频，不要配那种夸张探店旁白。

输入资源建设规格：待制作：多摊位手机视频、环境声音、商贩拍摄许可说明。

执行模式：冻结素材包　**主要能力：**E,I

评测者隐藏观察点

- 食品镜头不能错配店家，未核实价格不上字幕。
- 环境音与节奏塑造现场感，适度降噪。
- 镜头取舍不以单纯快切替代真实游逛过程。

第二轮用户反馈： “配乐有点抢了夜市自己的声音，多留些现场声可以吗？”

D39 街头乐队演出的三首歌

60–120秒 · 高

发给 Agent 的用户原话

> 上周拍了朋友乐队的街头表演，好几个角度，声音也有些炸。想剪个一分多钟的精华，让没来的人感受到现场氛围。

输入资源建设规格：待制作：同步录制的多机位、单独音轨、表演者授权。

执行模式：冻结素材包　**主要能力：**E,P

评测者隐藏观察点

- 跨机位同步同一段音乐和演奏动作。
- 避免把不同歌曲音频拼接成一段“现场实录”而不说明。
- 削波/降噪处理适度，不破坏现场动态。

第二轮用户反馈： “鼓点切镜头挺有意思，但主唱嘴型有几处对不上，修一下。”

D40 旧相册里的家庭故事

60–120秒 · 高

发给 Agent 的用户原话

> 整理家里旧照片，发现不同年份都在同一个地方拍过合照。想做个小视频送给家人，让他们看到时间过去的感觉，别太催泪。

输入资源建设规格：待制作：有年份标注的老照片 12–20 张、家庭授权音频、人物同意记录。

执行模式：冻结素材包　**主要能力：**E,V,I

评测者隐藏观察点

- 时间与人物顺序符合照片元数据，不虚构年代。
- 照片局部动画与修复不改变关键人物特征。
- 在保留私密性前提下建立时间和地点的呼应。

第二轮用户反馈： “有几张照片的脸被你处理得有点不像本人了。能尽量保留原样吗？”

TASK COLLECTION / E

复杂约束与跨模态制作 · 10 题

10 道信息、现有素材与多目标混合任务。重点是理解隐含约束与自主权衡。

E41 地震避险一分钟

45–75秒 · 高

发给 Agent 的用户原话

> 想做一条地震来了到底该怎么做的短视频，给家人群里转。别拍得太吓人，最好真的能记住有用的做法。

输入资源建设规格：需指定适用国家/地区并冻结当地官方应急指南；使用合规演示素材。

执行模式：开放网络　**主要能力：**R,P,I

评测者隐藏观察点

- 以适用地区的官方指南为准，区分室内、室外等情境。
- 不通过灾难特效制造错误动作或恐慌。
- 短时间内优先传达少量关键行动，信息准确可读。

第二轮用户反馈：“我爸妈说太快了，看完记不住。把最重要的动作讲得更清楚些。”

E42 大学开放日的非官方预告

45–90秒 · 中

发给 Agent 的用户原话

> 我们社团帮学院做开放日预告，手上有实验室、学生聊天和校园风景的素材。想做得有活力一点，不要那种十年前的学校宣传片。

输入资源建设规格：待制作：校园授权素材、活动日期地点、学院审核要点。

执行模式：冻结素材包　**主要能力：**P,E,I

评测者隐藏观察点

- 活动信息准确，避免未经确认的招生承诺。
- 学生生活、实验室与活动内容有清晰关系。
- 注意校徽等官方标识使用边界和人物授权。

第二轮用户反馈：“现在有点太“燃”了，看着像体育赛事。能更像学生真实的一天吗？”

E43 独立游戏版本更新预告

30–60秒 · 高

发给 Agent 的用户原话

> 我们游戏更新了几个小功能，录了玩法和 UI。想做个玩家看得懂又有点惊喜的更新视频，别整成电影预告弄得找不到实际更新点。

输入资源建设规格：待制作：游戏实录、版本更新说明、Logo、角色和关卡原始素材。

执行模式：冻结素材包　**主要能力：**P,V,E,I

评测者隐藏观察点

- 功能展示必须与真实版本一致，不能用预渲染欺骗玩法。
- 将更新点按玩家体验组织而非流水账。
- 声音/特效与游戏实际机制保持一致。

第二轮用户反馈： “画面很帅，但玩家说没看出这次到底更新了啥。每个重点能再清楚点吗？”

E44 一台相机的入门教程

60–120秒 · 高

发给 Agent 的用户原话

> 我拍了相机的几个按键和自己操作的片段，想帮新手做一条快速上手视频。不要说太多术语，也别只有手在按按钮看不出效果。

输入资源建设规格：待制作：手部实拍、相机菜单录屏、参数前后示例照片及型号资料。

执行模式：冻结素材包　**主要能力：**R,P,V

评测者隐藏观察点

- 操作顺序可复现，菜单文字与机器型号匹配。
- 通过前后画面对比说明设置影响，避免因果错配。
- 技术镜头与画面放大清晰，字幕不过载。

第二轮用户反馈： “讲得不错，但新手不一定知道你什么时候按了哪个按钮。能标得清楚些吗？”

E45 共享单车：三个街坊怎么说

60–120秒 · 高

发给 Agent 的用户原话

> 我采访了三个人，聊我们街区共享单车停放的问题，观点不太一样。能帮我剪条有观点但不带节奏的短纪录吗？想让人听完能理解双方。

输入资源建设规格：待制作：3 份访谈录音/录像、街景 B-roll、事件说明卡与授权。

执行模式：冻结素材包　**主要能力：**R,P,E,I

评测者隐藏观察点

- 不能断章取义或混合不同受访者话语。
- 准确呈现不同利益相关者诉求，不制造虚假对立。
- 论点与现场证据分明，字幕有明确归属。

第二轮用户反馈： “有一位受访者的观点被剪得特别极端，他原话不是这个意思。麻烦改客观点。”

E46 把一张电费表讲成故事

45–90秒 · 中

发给 Agent 的用户原话

> 我整理了家里一年的用电数据，想做条短视频看看什么时候用电最多。不要把 Excel 念一遍，做得直观点，最好还能解释几个可能原因。

输入资源建设规格：待制作：12 个月虚构但自洽的用电/账单 CSV、月度生活备注。

执行模式：冻结数据包　**主要能力：**R,V,P,I

评测者隐藏观察点

- 严格基于 CSV 计算和展示趋势，单位与金额分清。
- 区分数据可推断结论和只属于猜测的原因。
- 图表运动与口播同步，可视化可读不误导。

第二轮用户反馈： “你说夏天一定是空调导致的，但我们家没有记录空调开了多久。改得严谨点。”

E47 微波炉会把营养都破坏吗？

60–90秒 · 高

发给 Agent 的用户原话

> 家人老说微波炉加热会把营养全破坏掉。我想做条能转发的解释视频，别像在网上吵架，能不能用比较直观的方式讲清楚。

输入资源建设规格：食品科学和权威健康科普来源；不针对个体医疗情况。

执行模式：开放网络　**主要能力：**R,P,I

评测者隐藏观察点

- 纠正“全部破坏”的绝对化表述，注意食物/方法/条件差异。
- 不虚构实验演示与数值；科学概念做准确可视化。
- 语气尊重普通人的疑问，不靠嘲笑推动传播。

第二轮用户反馈：“科学内容是对的，但语气有点像在批评老人。说得更平和一点好吗？”

E48 长线上分享会剪成精华

60–120秒 · 高

发给 Agent 的用户原话

> 我们做了一个一小时的线上分享会，内容不错但实在太长。想剪一条一分多钟的精华，别人看完能知道讲了什么，也愿意去看完整版。

输入资源建设规格：待制作：完整会议录像、字幕/转写、演讲者授权和真实活动信息。

执行模式：冻结素材包　**主要能力：**R,P,E

评测者隐藏观察点

- 准确摘取原话，避免改变话语含义和时序。
- 有主题递进与完整观点，不是金句堆砌。
- 可读图示与讲话片段同步，素材裁切不丢关键内容。

第二轮用户反馈：“剪得挺精彩，但感觉只剩下几个口号，真正有用的观点没留下。调一下取舍。”

E49 一件文物的复原想象

60–100秒 · 高

发给 Agent 的用户原话

> 朋友在做一个小展览，想让观众看看一件残损器物原来可能是什么样。帮忙做个短视频，有点沉浸感，但不能让观众以为复原就是确定的历史事实。

输入资源建设规格：待制作：获授权器物照片/三维扫描、出处档案、研究者复原依据。

执行模式：冻结素材包+开放网络　**主要能力：**R,V,I

评测者隐藏观察点

- 分清实物证据、研究推断与艺术化重建。
- 三维形态、缺损部位和纹饰来源可追溯。
- 从残件到复原的视觉转换清晰，包含适度不确定性提示。

第二轮用户反馈：“复原太像已经确定的真相了。能让观众知道哪些部分还是猜的吗？”

E50 流浪动物领养活动倡导

45–90秒 · 高

发给 Agent 的用户原话

> 我们要做一次流浪动物领养日，拍了一些猫狗和志愿者的画面。帮我做条让人愿意关注的短视频，感人可以，但别弄得太惨。

输入资源建设规格：待制作：动物/志愿者授权照片视频、领养流程、活动信息和健康说明。

执行模式：冻结素材包　**主要能力：**R,P,E,I

评测者隐藏观察点

- 动物个体信息真实，不编造受虐背景或治疗结论。
- 领养流程与责任说明准确，避免情感绑架。
- 兼顾温暖影像和可执行活动信息，保护志愿者隐私。

第二轮用户反馈：“现在太像在煽情了。我更想让人觉得领养是一件要认真考虑、但很温暖的事。”

EVALUATION PROTOCOL

5. 统一评分规则

首轮作品评分 Q1 满分 100。维度采用 **0–4 的行为锚定等级**，再按维度权重换算：0 = 缺失/严重错误；1 = 大面积失败；2 = 部分达标；3 = 可靠达标；4 = 优秀且自洽。每个任务的隐藏观察点用于支撑举证，而不是指定唯一制作路径。

首轮评价维度	权重	可观察证据
Intent Alignment / 意图对齐	25	观众定位、风格、隐含目标、用户误解处理、必要的取舍
Research & Grounding / 事实与资料	15	来源可靠性、信息核查、版权与素材溯源、准确使用事实卡
Planning & Storytelling / 规划叙事	20	结构、镜头动机、信息安排、时间与空间连续性
Visual & VFX / 视觉特效	15	画质、主体一致性、合成可信度、图表/特效的叙事价值
Editing & Sound / 编排音效	15	镜头节奏、音画同步、字幕可读性、音乐及环境音关系
Execution & Delivery / 执行交付	10	工程成功率、异常恢复、输出可播放、文件与日志齐全

适用性： 未必每题都需要网络检索。Research 维度在创意任务中主要评价素材来源、内部事实卡忠实性和合理求证，避免对“没有必要联网”的 Agent 扣分。只会拼镜头或只生成视觉上好看的短片，不应自动获得规划/意图满分。

5.1 严重错误与门槛

- **交付门槛：** 没有能解码的完整视频，则 Q1 标记为未完成（不只是在综合分中扣 10 分）。
- **高风险内容门槛：** 公众安全说明出现可能导致伤害的错误、或故意把合成画面冒充新闻纪实，须单列重大失败标识。
- **版权与隐私：** 未经授权使用受保护资产、泄露私人资料等作为独立的合规标识；不以画面质量抵消。
- **无需规定特效数量：** 只有特效能提高表达时才加分，不奖励无效炫技。

5.2 第二轮修改单独评分

Revision score R（100 分）	权重
反馈问题是否被解决（Compliance）	40
其他正确内容的保留（Preservation）	30
修订后可感知质量提升（Delta）	20
额外时间、工具成本及修改范围控制（Efficiency）	10

建议将 **Q1 和 R 作为两个主要排行榜指标**，另可报告参考综合分 **0.7 × Q1 + 0.3 × R**。如果 v1 或 v2 缺失，应同时公开具体失败率；仅比较有产物样本会造成幸存者偏差。

6. 评估器与复现协议

- **程序化层：** 用 ffprobe 检查视频/音频轨、时长、帧率、黑屏与静音区段，OCR/VAD 辅助对齐字幕与口播（不能直接替代人工）。
- **证据层：** 事实任务核对权威来源/冻结事实卡；商业任务核对产品信息和授权；创意任务检查跨镜头主体、道具与故事逻辑。
- **多模态评审层：** 评估计划、构图、空间连续性、视频与意图一致性。按指定时间片抽帧，辅以音频和完整视频，以减少“只看静态帧”的偏差。
- **人评层：** 每个成片至少 3 位盲评者；提供用户原始提示词但不提供系统身份。重大分歧仲裁并报告评审一致性。
- **用户层：** 为评估真实意图对齐，可让目标受众对同题两个版本做匿名 A/B 比较，不能只靠 LLM-as-a-Judge。
- **预算与日志：** 固定工具权限和消耗上限（GPU 分钟、推理调用、网络访问、运行墙钟时间）；对不同预算分赛道，记录每次调用、来源与失败重试。
- **重复与统计：** 正式排行榜每个系统×任务至少 3 次独立运行；报告均值、95% 区间、完成率和各领域子分数，而非仅总体排序。

6.1 建议机器可读字段

`id`, `category`, `user_prompt`, `input_mode`, `required_asset_manifest`, `hidden_checks`, `revision_prompt`, `evaluation_weights`, `source_snapshot_date`, `evaluator_notes`, `license_status`。本次随 PDF 附带 50 题 JSON 规格，便于后续生成任务包与评分器。

7. 基线与消融实验

系统设置	目的
固定视频工作流	对照“LLM 生成脚本→选素材→生成→FFmpeg 拼接”的固定流程
通用 Agent + 标准工具	测自主规划、信息检索和跨工具协作
视频专用 Agent	测针对镜头/时间轴/返工优化后的收益
去除搜索 / 去除自检 / 无局部修改	判断事实正确性、返工效率、意图理解分别来自何种能力

控制变量： 主赛道要求一致素材和相近工具权限；“自由工具”可作为开放赛道，但不能与固定工具赛道混成同一排行榜。将任务难度与内容类型分层报告，并记录不同视频生成后端的影响。

8. 题库成熟度与工作清单

> **当前成果是 50 道完整任务定义，不是已经收集好的可执行数据集。** A 类和部分 E 类可以在完成来源冻结后较快试跑；B、C、D 及多数 E 类需统一采集、制作、授权素材包。未提供这些素材前，不应把模型的失败归因于它不会视频编辑。

1. 为 50 题建立标准资产 manifest、SHA-256 和使用授权；制作虚构品牌、虚构产品事实卡与合规示例。
2. 组织试标注：至少 5–10 个代表性 Agent 运行，检查题目歧义、难度分布和评分锚点是否足够稳定。
3. 组织盲评校准：独立评审分别评价视频，计算一致性；修改容易奖励“形式主义”的评分项。
4. 对开放检索题建立可复现的证据快照，记录网页更新时间；动态事实避免假设 2026 年后仍不变。
5. 经试跑和复标后，再发布正式数据集、评测脚本、样例运行及统计结果。

9. 相关基准与可借鉴原则

下列研究作为评测方法参考，不意味着它们已覆盖本设计中的全部开放式创作能力。

1. **Timeline-Bench**（2026）：从素材和客户简报产出完整视频，对交付、内容约束、显式要求与人评质量分层打分。
   https://timelinebench.tensortest.com/docs
2. **VBench**（CVPR 2024）：面向视频生成质量与语义一致性的细粒度维度评价。
   https://openaccess.thecvf.com/content/CVPR2024/html/Huang_VBench_Comprehensive_Benchmark_Suite_for_Video_Generative_Models_CVPR_2024_paper.html
3. **CutCraft / CutCrafter Benchmark**：剪辑与蒙太奇的专业维度评估方案，可参考音画编排的测量方法。
   https://github.com/AlibabaResearch/cut-craft-bench
4. **NASA DART mission**：A01 的权威事实参照，需区分早期 32 分钟、后续约 33 分钟的双星周期变化，与另行测得的日心轨道周期变化。
   https://science.nasa.gov/solar-system/asteroids/didymos/

文档日期：2026-11-01。相关工作链接已核验。所有未实际采集的原始视频素材均标注为“待制作”；任何能力分数与任务难度均属于方案设计，不代表真实实验结果。